T527 NPU 常见网络性能测试报告

版本号: 2.0
发布日期: 2024.11.13

广州星翼电子科技有限公司zdyzlinux

版本历史

版本号	日期	制/修订人	内容描述
1.0	2023.04.10	AWA2090	NPU 常见网络性能测试报告初始版本
2.0	2024.11.13	AWA1382	补充常见模型的数据。

广州星翼电子科技有限公司zdyzlinux

版权所有 © 珠海全志科技股份有限公司。保留一切权利

目　录

1 前言 **1**

1.1 文档简介 1

1.2 目标读者 1

1.3 适用范围 1

1.4 术语，缩略语及概念 1

2 环境搭建 **2**

3 测试步骤 **3**

4 公开模型的性能测试 **5**

5 公开模型的资源情况 **6**

6 附录 **7**

广州星翼电子科技有限公司zdyzlinux

1 前言

1.1 文档简介

介绍 NPU 模块的常见网络性能的测试报告，为 NPU 驱动、算法开发提供参考。

1.2 目标读者

本文档（本指南）主要适用于以下人员：

- 技术支持工程师
- 软件开发工程师
- AI 应用案客户

1.3 适用范围

硬件平台：T527 平台

软件平台：Linux5.15 系统（buildroot）、Android 13 系统

1.4 术语，缩略语及概念

术语	解释说明
NPU	Neural Network Processing Unit，神经网络处理器，采用 “数据驱动并行计算” 的架构，擅长处理视频、图像类的海量多媒体数据。
VIPLite	VIPLite 版本 NPU 驱动。
Unified	Unified 版本 NPU 驱动。
带宽	发送信号中含有的有效成分的效率范围，可以用来标识信号传输的数据传输能力，简写 BW。

版权所有 © 珠海全志科技股份有限公司。保留一切权利

2 环境搭建

修改设备树配置 NPU 模块的时钟频率为 546MHz/696MHz 进行测试：

```
        interrupt-names = "npu";
-       npu-vf = <696>;
+       npu-vf = <546>;
+       ##npu-vf = <696>;
        power-domains = <&pd A523_PD_NPU>;
```

编译 NPU 驱动并传到板端挂载（编译进内核不需要）：

```
##挂载VIPLite版本NPU驱动
insmod vipcore.ko
##挂载Unify版本NPU驱动
insmod galcore.ko
```

挂载动态库，公版方案中已预置动态库，若无预置使用adb push方式将动态库推到板端/usr/lib或者其他目录下：

VIPLite 版本动态库有：

```
├── libVIPlite.so
└── libVIPuser.so
```

Unified 版本动态库有：

```
├── libCLC.so
├── libGAL.so
├── libGLSLC.so
├── libNNGPUBinary.so
├── libNNVXCBinary.so
├── libOpenVX.so
├── libOpenVX.so.1
├── libOpenVX.so.1.3.0
├── libOpenVXU.so
├── libOvx12VXCBinary.so
├── libOvxGPUVXCBinary.so
└── libovxlib.so
```

若推到其他目录下时，请配置环境变量（使用静态库编译例程时不需要）：

```
export LD_LIBRARY_PATH=/xxx/xxx
```

版权所有 © 珠海全志科技股份有限公司。保留一切权利

3 测试步骤

本文以 VIPLite 版本 NPU 驱动为例，使用 vpm_run 程序进行测试。vpm_run 程序使用方法请参考《NPU_ 模型部署 _ 开发指南》。公版方案中已预置 vpm_run 程序，若无预置参考《NPU_ 模型部署 _ 开发指南》的《模型运行工具 vpm_run 使用说明》一节进行编译。

1. 将测试用例以及模型和输入使用adb push传入板端；
2. 配置sample.txt指定模型与输入；

```
[network]
./network_binary.nb
[input]
./input.dat
```

3. 运行测试用例：

```
chmod +x vpm_run
##运行例程 -l 100：推理100次
./vpm_run -s sample.txt -l 100
```

4. 输出结果，分析 LOG 得出结论。

```
/xx/test/vpm_run # ./vpm_run -s sample.txt -l 100
loop_count=100, device_id=0, file_name=sample.txt
test started.

init vip lite, driver version=0x00010d00...
VIPLite driver software version 1.13.0.0-AW-2023-10-19
vip lite init OK.

cid=0x10000016, device_count=1
  device[0] core_count=1
init test resources, batch_count: 1 ...
create/prepare networks ...
batch i=0, binary name: ./network_binary.nb
input 0 dim 224 224 3 1, data_format=2, quant_format=2, name=input[0], scale=0.007843, zero_point=128
ouput 0 dim 2 1 0 0, data_format=2, name=uid_1_out_0, scale=0.065554, zero_point=128
nbg name=./network_binary.nb
create network 0: 1763 us.
memory pool size=1092608byte
network core count=1
input 0 name: ./input_0.dat
prepare network 0: 2214 us.
```

版权所有 © 珠海全志科技股份有限公司。保留一切权利

```
batch: 0, loop count: 1
start to run network=./network_binary.nb
run time for this network 0: 15075 us.
run network done...
#第1次推理时间
profile inference time=14678us, cycle=10127721
******* nb TOP5 ********
...
...
batch: 0, loop count: 100
start to run network=./network_binary.nb
run time for this network 0: 15125 us.
run network done...
#第100次推理时间
profile inference time=14701us, cycle=10101912
******* nb TOP5 ********
 --- Top5 ---
...

#分析log，可知平均推理时间为14678us
batch 0, profile avg inference time=14678us, cycle=10127721
destroy teset resource batch_count=1
```

版权所有 © 珠海全志科技股份有限公司。保留一切权利

4 公开模型的性能测试

测试各模型的帧率（推理 1000 次）、带宽占用等情况，对 546MHz 以及 696MHz 频率的 NPU 模块以及 924GHz 的 DRAM 进行测试。

模型名称	输入分辨率	量化精度	FPS(546)	FPS(696)	ReadBW(MB)	WriteBW(MB)
yolov3	3x416x416	uint8	13.02	15.74	110.83	36.82
yolov4-tiny	3x416x416	uint8	92.23	115.11	10.77	4.02
yolov5s-sim	3x640x640	uint8	16.74	20.56	47.71	23.40
yolov5m	3x608x608	uint8	9.16	11.14	112.14	56.69
yolov7	3x640x640	uint8	4.23	5.18	276.81	72.83
yolov9c	3x640x640	uint8	3.98	4.82	270.55	125.66
ssd_mobilenet_v1	300x300x3	uint8	125.03	155.35	9.54	2.59
alexnet	3x227x227	uint8	34.97	44.45	24.20	0.81
inception_v3	299x299x3	uint8	29.13	35.88	34.24	5.26
inception_v4	299x299x3	uint8	14.35	17.55	79.29	13.05
mobilenetv1_1.0	224x224x3	uint8	274.57	347.58	4.36	1.29
mobilenetv2-12	3x224x224	uint8	293.77	348.43	5.47	2.16
resnet50v2	3x224x224	uint8	30.96	38.49	33.26	8.80
fairmot_crowdhuman	3x608x1088	uint8	2.57	3.04	361.58	459.55
yolact_resnet50	3x550x550	uint8	4.09	4.91	263.25	203.23
openpose	3x184x184	uint8	15.53	19.72	61.88	4.34
alphaPose_hard68	3x256x192	uint8	4.69	5.94	55.23	13.68
handpose_x	3x256x256	uint8	78.08	94.54	18.34	9.84
PFLD98-sim	3x112x112	uint8	610.87	778.21	1.18	0.06
Swin_MLP	3x224x224	uint8	7.09	8.7	74.29	36.59
Swin_Transformer	3x224x224	uint8	3.33	4.01	253.84	63.22
Swin_Transformer_v2	3x224x224	uint8	2.29	2.78	357.66	71.91
SimpleViT-sim	3x256x256	uint8	14.43	17.98	62.09	6.00
T2TViT-sim	3x256x256	uint8	1.31	1.6	454.52	220.42

版权所有 © 珠海全志科技股份有限公司。保留一切权利

5 公开模型的资源情况

以下为测试的公开模型的资源占用情况，内存占用统计使用了 VmHWM 值：

模型名称	输入分辨率	量化精度	模型大小（MB）	内存占用（MB）
yolov3	3x416x416	uint8	37.43	38.08
yolov4-tiny	3x416x416	uint8	3.48	3.69
yolov5s-sim	3x640x640	uint8	6.48	7.63
yolov5m	3x608x608	uint8	14.26	15.11
yolov7	3x640x640	uint8	24.28	26.67
yolov9c	3x640x640	uint8	18.27	20.46
ssd_mobilenet_v1	300x300x3	uint8	4.49	4.94
alexnet	3x227x227	uint8	45.49	45.66
inception_v3	299x299x3	uint8	16.61	16.89
inception_v4	299x299x3	uint8	28.85	29.18
mobilenetv1_1.0	224x224x3	uint8	2.96	3.14
mobilenetv2-12	3x224x224	uint8	2.96	3.20
resnet50v2	3x224x224	uint8	16.52	16.71
fairmot_crowdhuman	3x608x1088	uint8	15.89	17.41
yolact_resnet50	3x550x550	uint8	24.13	24.89
openpose	3x184x184	uint8	31.76	31.95
alphaPose_hard68	3x256x192	uint8	2.73	20.67
handpose_x	3x256x256	uint8	2.69	2.93
PFLD98-sim	3x112x112	uint8	1.11	1.27
Swin_MLP	3x224x224	uint8	20.73	22.16
Swin_Transformer	3x224x224	uint8	38.89	42.66
Swin_Transformer_v2	3x224x224	uint8	47.22	52.07
SimpleViT-sim	3x256x256	uint8	56.98	57.50
T2TViT-sim	3x256x256	uint8	70.66	72.05

版权所有 © 珠海全志科技股份有限公司。保留一切权利

6 附录

公开模型获取途径如下：

分类	模型	获取途径
目标检测	yolov3	cfg、weights
目标检测	yolov5s-sim	下载
目标检测	yolov9c	下载
目标检测	ssd_mobilenet_v1	下载
分类	alexnet	下载，权重
分类	resnet50v2	下载
分类	mobilenetv1_1.0	下载
分类	mobilenetv2-12	下载
分类	inception_v3	下载
分类	inception_v4	下载
多目标跟踪	fairmot_crowdhuman	下载
实例分割	yolact_resnet50	下载
人体姿态估计	openpose	下载
人体姿态估计	alphaPose_hard68	下载
手部关键点	handpose_x	下载
人脸关键点	PFLD98-sim	下载
Transformer 骨干	Swin_Transformer	下载
Transformer 骨干	Swin_Transformer_v2	下载
MLP	Swin_MLP	下载
Transformer 骨干	T2TViT-sim	下载
Transformer 骨干	SimpleViT-sim	下载

版权所有 © 珠海全志科技股份有限公司。保留一切权利

著作权声明

版权所有 ©2024 珠海全志科技股份有限公司。保留一切权利。

本文档及内容受著作权法保护，其著作权由珠海全志科技股份有限公司（“全志”）拥有并保留一切权利。

本文档是全志的原创作品和版权财产，未经全志书面许可，任何单位和个人不得擅自摘抄、复制、修改、发表或传播本文档内容的部分或全部，且不得以任何形式传播。

商标声明

、、全志科技、（不完全列举）均为珠海全志科技股份有限公司的商标或者注册商标。在本文档描述的产品中出现的其它商标，产品名称，和服务名称，均由其各自所有人拥有。

免责声明

您购买的产品、服务或特性应受您与珠海全志科技股份有限公司（“全志”）之间签署的商业合同和条款的约束。本文档中描述的全部或部分产品、服务或特性可能不在您所购买或使用的范围内。使用前请认真阅读合同条款和相关说明，并严格遵循本文档的使用说明。您将自行承担任何不当使用行为（包括但不限于如超压，超频，超温使用）造成的不利后果，全志概不负责。

本文档作为使用指导仅供参考。由于产品版本升级或其他原因，本文档内容有可能修改，如有变更，恕不另行通知。全志尽全力在本文档中提供准确的信息，但并不确保内容完全没有错误，因使用本文档而发生损害（包括但不限于间接的、偶然的、特殊的损失）或发生侵犯第三方权利事件，全志概不负责。本文档中的所有陈述、信息和建议并不构成任何明示或暗示的保证或承诺。

本文档未以明示或暗示或其他方式授予全志的任何专利或知识产权。在您实施方案或使用产品的过程中，可能需要获得第三方的权利许可。请您自行向第三方权利人获取相关的许可。全志不承担也不代为支付任何关于获取第三方许可的许可费或版税（专利税）。全志不对您所使用的第三方许可技术做出任何保证、赔偿或承担其他义务。